



UNIVERSIDAD NACIONAL AUTÓNOMA DE
MÉXICO

FACULTAD DE CIENCIAS

Diplomado Introducción Analítica a la Ciencia de Datos



MÓDULO 8

PROYECTO FINAL: ANÁLISIS DE RESULTADOS DE LA PREMIER LEAGUE

Fútbol y mercados de apuestas: Modelado Poisson para
la predicción de resultados de la Premier League

EQUIPO NÚMERO 1

INTEGRANTES

Castillo Rodríguez Daniel Arturo
Castillo Santiago Erika Isabel
Garduño Gutiérrez César Emiliano
Gómez Mendoza Maximiliano
Martínez Vega Eduardo
Zacateco Tello María Fernanda

Profesora

Claudia Juarez

30 de Septiembre de 2026

Índice

1	Resumen	1
2	Planteamiento del problema y objetivos	2
2.1	Pregunta de investigación	2
2.2	Hipótesis de investigación	2
3	Limpieza y preparación de datos	3
3.1	Limpieza e integración	4
3.2	Separación temporal	4
4	Ingeniería de variables	5
4.1	Sistema de fortaleza Elo	5
4.2	Promedios de goles por temporada	5
4.3	Forma reciente, remates y tiros a puerta	6
5	Fundamento estadístico del predictor	7
5.1	Regresión de Poisson para los goles	7
5.2	Resultados 1X2 y distribución de Skellam	8
6	Diseño experimental y especificaciones	8
6.1	Métricas de evaluación	10
6.2	Referencias de comparación	10
7	Resultados de la estimación y diagnósticos	11
7.1	Coeficientes del modelo base	11
7.2	Colinealidad en el modelo base	11
8	Validación y selección de especificaciones	12
8.1	Comparación con las cuotas de apertura en validación	12
9	Evaluación final en el conjunto de prueba	13
9.1	Referencia de mercado en prueba	13
9.2	Análisis de resultados	13
10	Ejemplo de pronóstico individual	14
11	Reproducibilidad, supuestos y limitaciones	15
11.1	Reproducibilidad y control de calidad	15
11.2	Supuestos del modelo	15
11.3	Alcance y limitaciones	15
12	Conclusiones	16
A	Diccionario de variables	17
A.1	Variables de la base histórica consolidada	17
A.2	Variables del conjunto de modelación	18

1. Resumen

El proyecto desarrolla y evalúa un sistema probabilístico para la predicción de resultados de partidos de la Premier League mediante modelos de regresión de Poisson. El enfoque consiste en estimar de manera independiente el número esperado de goles del equipo local y del equipo visitante a partir de información histórica disponible antes de cada encuentro. Las intensidades estimadas se utilizan posteriormente para obtener probabilidades de victoria local, empate y victoria visitante mediante la distribución de Skellam, así como probabilidades asociadas a marcadores específicos. Para evaluar de manera incremental la aportación de distintos grupos de variables se estiman cinco especificaciones. El modelo **M0 (Base)** constituye la referencia e incluye la diferencia de fortaleza Elo y los promedios estacionales de goles a favor y en contra. A partir de esta base, **M1 (Forma)** añade indicadores de forma reciente en goles; **M2 (Tiros)**, estadísticas recientes de tiros realizados y concedidos; y **M3 (Tiros a puerta)**, estadísticas recientes de tiros a puerta realizados y concedidos. Finalmente, **M4 (Completo)** reúne simultáneamente todas las variables anteriores. Todas las características se construyen exclusivamente con información disponible antes de cada encuentro, preservando el orden temporal del problema de predicción.

Adicionalmente, se utilizó la referencia de mercado de apertura, construida a partir de las cuotas promedio de apertura $AvgH$, $AvgD$ y $AvgA$, transformadas en probabilidades implícitas normalizadas.

El histórico consolidado contiene 9,540 partidos disputados entre el 18 de agosto de 2001 y el 14 de septiembre de 2026, con 34 columnas de información; a partir de este histórico se construye una matriz de modelación de 2,696 encuentros comprendidos entre el 9 de agosto de 2019 y el 14 de septiembre de 2026. La muestra se divide cronológicamente en 1,897 partidos de entrenamiento, 380 de validación y 419 de prueba; esta separación temporal permite evaluar los modelos sobre encuentros posteriores a aquellos utilizados durante su estimación.

Las variables explicativas incluyen fortaleza relativa mediante puntuaciones Elo, promedios estacionales de goles anotados y recibidos, indicadores de forma reciente y estadísticas de tiros y tiros a puerta. Todas estas características se construyen utilizando únicamente información anterior a la fecha del encuentro objetivo, con el propósito de mantener una estructura temporal coherente con un problema real de predicción.

En validación, M0 registra el menor MAE medio entre las especificaciones desarrolladas, con 0.918332, mientras que M4 obtiene el menor LogLoss 1X2, con 0.978612 frente a 0.989547 de M0. En el conjunto de prueba, M3 presenta el menor MAE medio, con 0.894173, mientras que M0 obtiene el menor LogLoss entre los cinco modelos, con 1.033076; M3 registra un valor muy cercano de 1.033868. Estos resultados muestran que una mejor aproximación al número esperado de goles no implica necesariamente una mejor distribución de probabilidades entre victoria, empate y derrota.

Las probabilidades implícitas de las cuotas de apertura registran pérdidas logarítmicas de 0.970552 en validación y 1.020000 en prueba. Esta comparación permite dimensionar el desempeño probabilístico de los modelos, aunque no constituye una evaluación de rentabilidad ni una estrategia de apuestas.

En conjunto, el proyecto permite estudiar cómo diferentes grupos de variables históricas afectan la capacidad predictiva de un modelo Poisson aplicado al fútbol y muestra la importancia de evaluar por separado la precisión en la estimación de goles y la calidad de las probabilidades 1X2.

2. Planteamiento del problema y objetivos

Pronosticar un partido de fútbol implica cuantificar eventos discretos, sujetos a variabilidad incluso cuando se conoce la fuerza relativa de ambos equipos. En lugar de emitir únicamente un ganador, se busca construir una descripción probabilística que permita distinguir la victoria local, el empate y la victoria visitante, así como los marcadores concretos. Un pronóstico de esta clase requiere información disponible antes del inicio del encuentro y una validación que respete el orden temporal del calendario.

El objetivo general es desarrollar y evaluar un predictor de resultados de la Premier League a partir de características históricas de los clubes y modelos de regresión de Poisson. En particular, se busca consolidar datos de partidos; derivar variables de fortaleza, producción ofensiva, defensa y forma reciente; estimar dos intensidades de gol por encuentro; transformar las intensidades en probabilidades 1X2; comparar distintas especificaciones del modelo y contrastar su desempeño con una referencia sencilla y con las probabilidades implícitas en las cuotas de apertura.

La población de interés corresponde a los partidos de la Premier League inglesa dentro del periodo considerado en el estudio, y la unidad de análisis es cada partido disputado. El conjunto histórico consolidado comprende encuentros registrados entre el 18 de agosto de 2001 y el 14 de septiembre de 2026, mientras que la matriz utilizada para el modelado abarca partidos desde el 9 de agosto de 2019.

Las variables objetivo del modelado son los goles anotados por el equipo local y por el equipo visitante. A partir de sus distribuciones estimadas se obtienen posteriormente las probabilidades de victoria local, empate y victoria visitante. Como variables explicativas se consideran, según la especificación del modelo, indicadores de fortaleza relativa mediante Elo, promedios históricos de goles por temporada y medidas de forma reciente basadas en goles, tiros y tiros a puerta.

El alcance geográfico del análisis se limita a la Premier League de Inglaterra. El estudio tiene un alcance predictivo y comparativo: busca evaluar la capacidad de distintas especificaciones del modelo para generar pronósticos fuera de muestra y contrastar sus probabilidades con las probabilidades implícitas derivadas de las cuotas de apertura disponibles.

2.1. Pregunta de investigación

¿En qué medida la incorporación de variables históricas de fortaleza y desempeño reciente mejora la capacidad predictiva de un modelo probabilístico de resultados de partidos de la Premier League, y cómo se compara su desempeño con las probabilidades implícitas en las cuotas de apertura?

2.2. Hipótesis de investigación

La incorporación de información sobre la fortaleza relativa de los equipos y su desempeño reciente mejorará la capacidad predictiva respecto de un modelo base con menor información. En particular, se espera que los modelos ampliados presenten menores errores en la estimación de goles y una mejor calidad de las probabilidades estimadas de victoria local, empate y victoria visitante.

3. Limpieza y preparación de datos

El archivo comprimido contiene `E0_consolidado.csv`, `premier_training_data.csv`, `Limpieza de datos.ipynb`, `Analisis.ipynb` y `wc_predictor.py`. El cuaderno de limpieza documenta la integración, selección y revisión de los archivos históricos `E0.csv` descargados desde Football-Data [4], mientras que `E0_consolidado.csv` constituye la base histórica resultante de este proceso. El módulo `wc_predictor.py` contiene las funciones utilizadas para construir las variables prepartido, entre ellas las puntuaciones Elo, los promedios estacionales de goles y los indicadores de forma reciente. Finalmente, `Analisis.ipynb` organiza la construcción de la matriz de modelación, la estimación de las distintas especificaciones, la validación temporal, la evaluación fuera de muestra y la comparación de las probabilidades estimadas con las cuotas de apertura.

Cuadro 1: Bases y periodos observados en los archivos entregados.

Archivo	Filas	Columnas	Periodo observado
Histórico consolidado	9,540	34	18-08-2001 a 14-09-2026
Matriz de entrenamiento	2,696	24	09-08-2019 a 14-09-2026

El histórico consolidado contiene 23 variables disponibles de manera consistente en los archivos originales y 11 variables complementarias. Las primeras comprenden la identificación de los encuentros, resultados y estadísticas como goles, tiros, tiros a puerta, faltas, córners y tarjetas. Las variables complementarias corresponden principalmente a cuotas de apuestas y goles esperados (xG), cuya disponibilidad depende del periodo observado.

La disponibilidad de las variables complementarias no es homogénea a lo largo del periodo analizado. Los valores faltantes se concentran en las cuotas de apuestas y los goles esperados, mientras que las 23 variables principales se encuentran completas en todo el histórico. La Tabla 2 resume esta cobertura.

Cuadro 2: Cobertura histórica de las variables del conjunto consolidado.

Variables	Valores ausentes	Observaciones disponibles	Temporadas con información
Variables principales	0	9,540	2001/02–2026/27
B365H , B365D , B365A	380	9,160	2002/03–2026/27
AvgH , AvgD , AvgA , AvgCH , AvgCD , AvgCA	6,840	2,700	2019/20–2026/27
HxG , AxG	9,500	40	2026/27

La diferencia en cobertura responde a que estas variables fueron incorporándose progresivamente a los archivos de la fuente. Las cuotas de Bet365 están disponibles desde la temporada 2002/03, mientras que las cuotas promedio de mercado, tanto de apertura como de cierre, se encuentran en el consolidado desde 2019/20. Por su parte, las variables de goles esperados (xG) únicamente están disponibles para los encuentros registrados de la temporada 2026/27.

Estas ausencias no implican la eliminación de partidos del histórico. Las variables principales utilizadas para identificar los encuentros y describir sus resultados y estadísticas mantienen cobertura completa, mientras que las variables complementarias se utilizan únicamente en las etapas del análisis para las que existe información disponible.

3.1. Limpieza e integración

La construcción del conjunto de datos parte de 26 archivos históricos de resultados y estadísticas de la Premier League obtenidos de Football-Data. Primero se identificaron las variables disponibles en todos los archivos y se conservaron, adicionalmente, las variables complementarias de interés cuando estaban disponibles. Posteriormente, los archivos filtrados se integraron en un único conjunto de datos. Durante este procedimiento se eliminó una observación completamente vacía, obteniéndose una base final de 9,540 partidos y 34 variables.

Las fechas de los archivos originales presentan distintas representaciones a lo largo del histórico, por lo que se transformaron a un formato temporal homogéneo. Esto permite ordenar correctamente los encuentros y realizar posteriormente las particiones temporales y la construcción de variables prepartido sin alterar el orden cronológico de la información.

Como control adicional, se realizaron pruebas de consistencia sobre la base consolidada. Se revisó la existencia de partidos duplicados, equipos local y visitante coincidentes, valores negativos en estadísticas de juego, goles al descanso superiores a los goles finales, coherencia entre el marcador y el resultado registrado, cuotas inválidas y valores negativos de xG . También se comprobó que los tiros a puerta no superaran los tiros totales. Estas revisiones no mostraron problemas generalizados en las variables principales; únicamente se identificó una inconsistencia puntual entre tiros y tiros a puerta en un encuentro, por lo que se conservó la observación al mantenerse válida la información restante del partido.

La base consolidada resultante constituye el histórico a partir del cual se generan posteriormente las características utilizadas por los modelos. En particular, `wc_predictor.py` transforma la información histórica en variables estrictamente prepartido, como las puntuaciones Elo, los promedios estacionales de goles y las medidas de forma reciente. De esta manera, la preparación de los datos se separa en dos etapas: primero, la homologación y revisión del histórico original y, posteriormente, la construcción de la matriz empleada para estimar y evaluar los modelos de regresión de Poisson.

Al construir las variables prepartido se obtuvieron inicialmente 2,700 encuentros. Cuatro observaciones correspondían a equipos sin partidos previos disponibles en el histórico de Premier League y, por tanto, no era posible calcular sus medidas recientes de tiros y tiros a puerta sin imputar información. Estas observaciones se excluyeron para conservar una muestra común en M0–M4, por lo que la matriz final contiene 2,696 partidos.

3.2. Separación temporal

Se seleccionan observaciones a partir de agosto de 2019 para la matriz modelable, pero la historia anterior sirve para calcular variables retrospectivas y ratings Elo al inicio del experimento. La partición conserva la secuencia temporal en lugar de mezclar aleatoriamente partidos de distintas temporadas.

Cuadro 3: Partición cronológica de la base de modelación.

Conjunto	Partidos	Fechas presentes en la base
Entrenamiento	1,897	09-08-2019 a 19-05-2024
Validación	380	16-08-2024 a 25-05-2025
Prueba	419	15-08-2025 a 14-09-2026

Los modelos se ajustan con los encuentros anteriores al 1 de agosto de 2024. El intervalo comprendido entre esa fecha y el 1 de agosto de 2025 se utiliza para comparar especificaciones. La prueba comienza el 1 de agosto de 2025; sus 419 registros incluyen una temporada completa de 380 partidos y encuentros adicionales de la siguiente temporada. Para cualquier encuentro objetivo se construyen los atributos con un filtro estricto de fecha anterior, de modo que los partidos disputados el mismo día no se emplean como información previa unos de otros.

4. Ingeniería de variables

4.1. Sistema de fortaleza Elo

Cada club dispone de una puntuación Elo [1], inicializada en 1,500 puntos y actualizada con cada resultado. Para dos equipos con puntuaciones R_i y R_j , la expectativa de resultado del primero es

$$E_i = \frac{1}{1 + 10^{(R_j - R_i)/400}}, \quad R_i^{\text{nuevo}} = R_i^{\text{anterior}} + K(S_i - E_i), \quad K = 15. \quad (1)$$

donde S_i toma los valores 1, $1/2$ y 0 para victoria, empate y derrota. El procedimiento actualiza las puntuaciones de ambos contendientes después de registrar el resultado; en la regresión se utiliza la diferencia anterior al encuentro $\Delta R = R_{\text{local}} - R_{\text{visitante}}$, dividida entre 400. Esta normalización facilita la escala numérica de los coeficientes, sin cambiar la información Elo. El sistema implementado no incluye un ajuste de localía dentro de la fórmula Elo; la condición local/visitante se representa mediante ecuaciones de gol diferenciadas.

4.2. Promedios de goles por temporada

Para cada club se calculan promedios de goles anotados y recibidos a partir de la información disponible antes de la fecha del encuentro. Durante la calibración se consideró la siguiente formulación general:

$$\hat{g} = \frac{n}{n+k} \bar{g}_{\text{actual}} + \frac{k}{n+k} \bar{g}_{\text{previo}}, \quad (2)$$

donde n representa el número de partidos disponibles en la temporada actual, $\bar{g}_{\text{actual}}$ el promedio correspondiente a dicha temporada, $\bar{g}_{\text{previo}}$ el promedio de la temporada anterior y k determina el peso asignado a esta última referencia.

En la configuración seleccionada se utiliza $k = 0$. Por tanto, el peso de la temporada anterior es nulo y, siempre que existan observaciones de la temporada actual, el estimador se reduce a

$$\hat{g} = \bar{g}_{\text{actual}}. \quad (3)$$

Cuando un equipo todavía no ha disputado partidos en la temporada actual, el procedimiento utiliza como respaldo la información previa disponible; si el club no participó en la temporada anterior, se emplea el promedio de la liga de ese periodo. Este procedimiento se aplica de manera independiente a los goles a favor y en contra, utilizando únicamente encuentros anteriores al partido que se desea pronosticar.

Los hiperparámetros K del sistema Elo y k del cálculo de los promedios estacionales se evaluaron mediante validación temporal utilizando el Log-Loss de M0 como criterio. La configuración utilizada fue $K = 15$ y $k = 0$, con un Log-Loss temporal promedio de 0.959558 en los periodos de validación considerados.

4.3. Forma reciente, remates y tiros a puerta

La forma reciente resume los últimos diez partidos disponibles de cada equipo; no está restringida exclusivamente a partidos de una misma temporada. Las observaciones reciben pesos geométricos con $d = 0.85$:

$$w_j = \frac{d^{m-j}}{\sum_{\ell=1}^m d^{m-\ell}}, \quad \hat{z}_{\text{forma}} = \sum_{j=1}^m w_j z_j, \quad m \leq 10. \quad (4)$$

donde $j = m$ corresponde al partido más reciente. Se calculan promedios ponderados de goles a favor y en contra, tiros realizados y permitidos, y tiros a puerta realizados y permitidos. Para un club se homogeneiza la orientación de cada partido: al jugar de visitante, sus tiros a favor provienen de la columna de remates visitantes y sus tiros concedidos de los remates locales, y viceversa cuando juega en casa.

La matriz final contiene 19 columnas explicativas y de apoyo antes de agregar tres identificadores (fecha y equipos) y dos variables objetivo; en total son 24 campos. Más precisamente, por encuentro se conservan tres claves, dos Elo por equipo y su diferencia, cuatro promedios de goles por temporada, cuatro de forma goleadora, ocho de remates y dos resultados reales: $3 + 3 + 4 + 4 + 8 + 2 = 24$. La diferencia Elo evita que ambos ratings entren redundantes en la misma ecuación. Las columnas de cuotas y las variables HxG / AxG del archivo fuente no forman parte de las cinco especificaciones de regresión.




Figura 1: Flujo general de construcción, estimación y evaluación del sistema predictivo.

5. Fundamento estadístico del predictor

5.1. Regresión de Poisson para los goles

Se modela la cantidad de goles como una variable discreta no negativa [2]; para un equipo con intensidad $\lambda > 0$, la distribución de Poisson asigna la probabilidad

$$\mathbb{P}(Y = y \mid \lambda) = \frac{e^{-\lambda} \lambda^y}{y!}, \quad y = 0, 1, 2, \dots, \quad \mathbb{E}(Y \mid \lambda) = \lambda. \quad (5)$$

El modelo lineal generalizado utiliza un enlace logarítmico, que garantiza predicciones positivas: $\log \lambda_{L,i} = \beta_{L,0} + \mathbf{x}_{L,i}^\top \boldsymbol{\beta}_L$ y $\log \lambda_{V,i} = \beta_{V,0} + \mathbf{x}_{V,i}^\top \boldsymbol{\beta}_V$. Los coeficientes se estiman por máxima verosimilitud en entrenamiento mediante `statsmodels.api.GLM` con familia Poisson. Los regresores del equipo local y del visitante se construyen por separado, con sus estadísticas ofensivas y las estadísticas defensivas del rival.

La log-verosimilitud que se maximiza en cada ecuación tiene la forma

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^n [y_i \log(\lambda_i) - \lambda_i - \log(y_i!)], \quad \lambda_i = \exp(\mathbf{x}_i^\top \boldsymbol{\beta}). \quad (6)$$

A igualdad del resto de los regresores, un incremento de una unidad en una variable x_j multiplica la intensidad pronosticada por e^{β_j} . Por tratarse de un modelo condicional descriptivo, esta relación no equivale a identificar un efecto causal.

5.2. Resultados 1X2 y distribución de Skellam

El cálculo de probabilidades de resultados supone que, condicionados a los regresores, los goles locales Y_L y visitantes Y_V son independientes y siguen distribuciones de Poisson con intensidades λ_L y λ_V . Entonces la diferencia $D = Y_L - Y_V$ sigue una distribución de Skellam y permite obtener sin truncar la suma de marcadores:

$$\mathbb{P}(\text{victoria local}) = \mathbb{P}(D > 0) = 1 - F_D(0), \quad (7)$$

$$\mathbb{P}(\text{empate}) = \mathbb{P}(D = 0), \quad (8)$$

$$\mathbb{P}(\text{victoria visitante}) = \mathbb{P}(D < 0) = F_D(-1). \quad (9)$$

Las tres cantidades son no negativas y suman uno. Para estimar el marcador más probable se construye, por separado, una matriz de probabilidades de goles entre cero y diez por equipo:

$$\mathbb{P}(Y_L = i, Y_V = j) = \frac{e^{-\lambda_L} \lambda_L^i}{i!} \frac{e^{-\lambda_V} \lambda_V^j}{j!}, \quad i, j \in \{0, \dots, 10\}. \quad (10)$$

El máximo de esa matriz identifica el marcador modal dentro del rango considerado; no representa un resultado garantizado. Las probabilidades 1X2 reportadas se obtienen directamente mediante Skellam, no mediante esa matriz truncada ni por simulaciones Monte Carlo.

6. Diseño experimental y especificaciones

Las cinco especificaciones comparten dos ecuaciones de Poisson por encuentro: una para los goles del equipo local y otra para los goles del visitante. En cada una, el término `elo_diff` representa $(R_L - R_V)/400$; las variables `gf` y `ga` corresponden a los promedios estacionales de goles a favor y en contra; el prefijo `form` identifica las medidas recientes de goles; `shots` los tiros; y `sof` los tiros a puerta. Los sufijos `home` y `away` identifican al equipo local y visitante, respectivamente.

Cuadro 4: Especificaciones de los modelos y variables utilizadas en cada ecuación.

Modelo	Variables	Descripción conceptual	Variables utilizadas
M0 Base	3	Diferencia Elo, promedio estacional de goles a favor del equipo y promedio estacional de goles en contra del rival.	Local: <code>elo_diff</code> , <code>gf_home</code> , <code>ga_away</code> . Visitante: <code>elo_diff</code> , <code>gf_away</code> , <code>ga_home</code> .
M1 Forma	5	M0 más el desempeño reciente en goles: goles a favor del equipo y goles en contra del rival.	Local: <code>elo_diff</code> , <code>gf_home</code> , <code>ga_away</code> , <code>form_gf_home</code> , <code>form_ga_away</code> . Visitante: <code>elo_diff</code> , <code>gf_away</code> , <code>ga_home</code> , <code>form_gf_away</code> , <code>form_ga_home</code> .
M2 Tiros	5	M0 más tiros recientes realizados por el equipo y tiros recientes concedidos por el rival.	Local: <code>elo_diff</code> , <code>gf_home</code> , <code>ga_away</code> , <code>shots_for_home</code> , <code>shots_against_away</code> . Visitante: <code>elo_diff</code> , <code>gf_away</code> , <code>ga_home</code> , <code>shots_for_away</code> , <code>shots_against_home</code> .
M3 Tiros a puerta	5	M0 más tiros a puerta recientes realizados por el equipo y tiros a puerta recientes concedidos por el rival.	Local: <code>elo_diff</code> , <code>gf_home</code> , <code>ga_away</code> , <code>sot_for_home</code> , <code>sot_against_away</code> . Visitante: <code>elo_diff</code> , <code>gf_away</code> , <code>ga_home</code> , <code>sot_for_away</code> , <code>sot_against_home</code> .
M4 Completo	9	M0 más todas las variables adicionales de forma reciente, tiros y tiros a puerta.	Local: <code>elo_diff</code> , <code>gf_home</code> , <code>ga_away</code> , <code>form_gf_home</code> , <code>form_ga_away</code> , <code>shots_for_home</code> , <code>shots_against_away</code> , <code>sot_for_home</code> , <code>sot_against_away</code> . Visitante: <code>elo_diff</code> , <code>gf_away</code> , <code>ga_home</code> , <code>form_gf_away</code> , <code>form_ga_home</code> , <code>shots_for_away</code> , <code>shots_against_home</code> , <code>sot_for_away</code> , <code>sot_against_home</code> .

El número de variables reportado excluye el término constante de cada regresión. Las dos ecuaciones siguen la misma estructura: para estimar los goles del equipo local se utilizan sus características ofensivas y las características defensivas del visitante, mientras que para estimar los goles del visitante se invierte esta orientación.

Por ejemplo, las ecuaciones correspondientes a M0 son

$$\log(\lambda_L) = \beta_{L,0} + \beta_{L,1} \frac{R_L - R_V}{400} + \beta_{L,2} GF_L + \beta_{L,3} GA_V, \quad (11)$$

$$\log(\lambda_V) = \beta_{V,0} + \beta_{V,1} \frac{R_L - R_V}{400} + \beta_{V,2} GF_V + \beta_{V,3} GA_L. \quad (12)$$

M4 incorpora seis términos adicionales en cada ecuación. Los coeficientes se ajustan únicamente sobre los 1,897 partidos de entrenamiento. En validación se comparan M0–M4 y las cinco especificaciones se conservan también para la evaluación final en el conjunto de prueba. Los coeficientes estimados no se redefinen con la información de prueba. Los atributos de un partido de prueba sí pueden incorporar resultados de partidos cronológicamente anteriores del mismo periodo, pues estos ya eran conocidos en la fecha de predicción.

6.1. Métricas de evaluación

El error absoluto medio por lado compara los goles efectivamente anotados con su intensidad predicha:

$$\begin{aligned} \text{MAE}_L &= \frac{1}{n} \sum_{i=1}^n |y_{L,i} - \hat{\lambda}_{L,i}|, \\ \text{MAE}_V &= \frac{1}{n} \sum_{i=1}^n |y_{V,i} - \hat{\lambda}_{V,i}|, \\ \text{MAE}_{\text{medio}} &= \frac{\text{MAE}_L + \text{MAE}_V}{2}. \end{aligned} \tag{13}$$

Esta métrica describe la precisión de las medias de goles y no la calidad de toda la distribución. Para evaluar las probabilidades de las tres clases se utiliza la pérdida logarítmica [3]:

$$\text{LogLoss}_{1X2} = -\frac{1}{n} \sum_{i=1}^n \log(\hat{p}_{i,y_i}). \tag{14}$$

donde $\hat{p}_{i,y_i}$ es la probabilidad atribuida al resultado real. Cuanto menor es la pérdida, mayor probabilidad se asignó, en promedio logarítmico, a los resultados observados; penaliza fuertemente las predicciones excesivamente confiadas cuando el evento anticipado no sucede. Ambas métricas se reportan porque optimizan criterios distintos.

6.2. Referencias de comparación

Como referencia sencilla se utiliza un modelo con intensidades constantes iguales a las medias de entrenamiento: $\lambda_L = 1.561413$ y $\lambda_V = 1.311545$. Este procedimiento no distingue entre clubes y permite verificar si los regresores agregan capacidad descriptiva fuera de la muestra de ajuste. De forma separada, las cuotas decimales promedio de apertura o_L, o_E, o_V se convierten en probabilidades implícitas normalizadas,

$$q_k = \frac{\frac{1}{o_k}}{\sum_{j \in \{L, E, V\}} \frac{1}{o_j}}, \quad k \in \{L, E, V\}. \tag{15}$$

La normalización elimina el exceso de probabilidad implícita del conjunto de cuotas. El margen bruto se resume como $\sum_j 1/o_j - 1$, expresado en porcentaje. La comparación se hace sobre los mismos encuentros que tienen las tres cuotas válidas y no constituye una simulación de estrategias de apuestas ni una medición de rentabilidad.

7. Resultados de la estimación y diagnósticos

7.1. Coeficientes del modelo base

El ajuste de M0 a los datos de entrenamiento produce los coeficientes de la tabla 5. El regresor Elo se encuentra dividido entre 400, por lo que el coeficiente cuantifica un desplazamiento de 400 puntos y no de un punto. Los coeficientes de producción ofensiva tienen signo positivo en ambas ecuaciones, mientras que el coeficiente de la diferencia Elo es positivo para los goles locales y negativo para los visitantes, manteniendo constantes los demás factores.

Cuadro 5: Coeficientes estimados de M0 en entrenamiento (1,897 partidos).

Regresor	Ecuación local	Ecuación visitante
Intercepto	0.0433	0.0264
Diferencia Elo / 400	0.6283	-0.6854
Goles a favor propios	0.1678	0.1079
Goles en contra del rival	0.0778	0.0281

Por ejemplo, en la ecuación local de M0, un aumento de 400 puntos en la diferencia Elo, con los demás predictores fijos, multiplica la intensidad de goles locales por $e^{0.6283} \approx 1.87$. La lectura es una asociación condicional dentro del modelo y no una regla determinista para un partido individual.

7.2. Colinealidad en el modelo base

El diagnóstico de multicolinealidad se realiza sobre los regresores de M0. En la ecuación local, las correlaciones de la diferencia Elo con los goles a favor propios y con los goles en contra del rival son 0.503 y 0.372, respectivamente; la correlación entre estos dos promedios de goles es 0.011. Los VIF correspondientes son 1.632 para la diferencia Elo, 1.407 para los goles a favor propios y 1.219 para los goles en contra del rival.

En la ecuación visitante, las correlaciones de la diferencia Elo con los goles a favor del visitante y con los goles en contra del local son -0.497 y -0.371, mientras que la correlación entre los dos promedios de goles es -0.038. Los VIF son 1.665, 1.438 y 1.255, respectivamente. Estos valores muestran que los regresores de M0 no presentan una redundancia lineal elevada dentro de la muestra de entrenamiento. El diagnóstico describe la relación entre predictores y no constituye por sí mismo una medida de calidad predictiva.

8. Validación y selección de especificaciones

En validación se evaluaron los cinco modelos utilizando los mismos 380 partidos de la temporada 2024/25. La tabla 6 presenta las métricas, sin ordenar las filas por desempeño para mantener identificables las especificaciones.

Cuadro 6: Resultados de validación: 380 encuentros. Valores menores indican menor error o pérdida.

Modelo	MAE local	MAE visitante	MAE medio	LogLoss 1X2	Diferencia LogLoss vs. M0
M0 Base	0.959641	0.877023	0.918332	0.989547	0.000000
M1 Forma	0.964160	0.878962	0.921561	0.987603	-0.001944
M2 Tiros	0.967058	0.875771	0.921414	0.980718	-0.008829
M3 SOT	0.962969	0.878943	0.920956	0.982319	-0.007228
M4 Completo	0.966128	0.877662	0.921895	0.978612	-0.010935

En esta partición, M0 presenta el menor MAE medio, con 0.918332. M4, en cambio, obtiene el menor LogLoss 1X2 entre las especificaciones desarrolladas, con 0.978612 frente a 0.989547 de M0, una disminución de 0.010935. M2 y M3 también reducen el LogLoss respecto de M0, aunque sus MAE medios son ligeramente superiores. La diferencia de criterio importa: elegir una especificación para estimar promedios de gol no es exactamente el mismo problema que elegirla para distribuir probabilidades entre tres resultados.

La referencia de intensidades constantes obtiene en validación MAE local de 1.054156, MAE visitante de 0.928139, MAE medio de 0.991147 y LogLoss 1X2 de 1.079361. Los cinco modelos condicionados a las características de los clubes presentan valores numéricamente inferiores a esa referencia en las dos métricas agregadas. La comparación no demuestra por sí sola estabilidad futura ni significación estadística de cada diferencia.

8.1. Comparación con las cuotas de apertura en validación

Los 380 partidos de validación contienen cuotas promedio de apertura válidas en sus tres desenlaces; el margen bruto promedio de esas cuotas es de 4.49 %. Tras convertirlas en probabilidades implícitas normalizadas, su LogLoss 1X2 es 0.970552, frente a 0.978612 de M4, 0.980718 de M2, 0.982319 de M3, 0.987603 de M1 y 0.989547 de M0. Se trata de una referencia informativa sobre calidad predictiva, no de una demostración de que se pueda operar a cuotas disponibles sin costes y obtener resultados económicos positivos.

9. Evaluación final en el conjunto de prueba

Una vez establecidas las especificaciones, se conservaron los parámetros estimados sobre entrenamiento y se evaluaron M0–M4 sobre los mismos 419 encuentros comprendidos entre agosto de 2025 y septiembre de 2026. La tabla 7 presenta los resultados fuera de muestra.

Cuadro 7: Resultados fuera del periodo de entrenamiento: prueba de 419 encuentros.

Modelo	MAE local	MAE visitante	MAE medio	LogLoss 1X2
M0 Base	0.954870	0.849741	0.902306	1.033076
M1 Forma	0.956394	0.850644	0.903519	1.034699
M2 Tiros	0.945434	0.857829	0.901631	1.037331
M3 SOT	0.937986	0.850360	0.894173	1.033868
M4 Completo	0.942293	0.856585	0.899439	1.036739

En esta partición, M3 obtiene el menor MAE medio entre las especificaciones desarrolladas, con 0.894173, una reducción de 0.008133 respecto de M0. En términos de LogLoss, M0 registra el menor valor, con 1.033076, seguido muy de cerca por M3 con 1.033868, una diferencia de 0.000792. M4 también mejora el MAE medio de M0, pero presenta un LogLoss superior. En consecuencia, el orden relativo de los modelos depende de la métrica utilizada y el incremento de complejidad no se traduce de manera uniforme en una mejor distribución de probabilidades 1X2. El cuaderno de análisis no incluye intervalos de confianza por remuestreo temporal, pruebas de calibración ni análisis de dispersión por temporada o club; el tablero del proyecto (<https://pitirringo.github.io/futbol-apuestas/>) complementa esta evaluación con intervalos bootstrap por remuestreo de partidos, gráficas de calibración y la dispersión de Pearson.

9.1. Referencia de mercado en prueba

Se dispuso de cuotas válidas para los 419 encuentros de prueba, con margen bruto promedio de 5.84 %. Sobre exactamente esa misma muestra, la pérdida logarítmica del mercado de apertura normalizado es 1.020000; los valores de M0, M1, M2, M3 y M4 son 1.033076, 1.034699, 1.037331, 1.033868 y 1.036739, respectivamente. La comparación evidencia una diferencia descriptiva en la calidad probabilística registrada durante el periodo; no identifica qué habría ocurrido en un entorno de predicciones en tiempo real ni constituye una evaluación de apuestas. La disponibilidad efectiva de las cuotas al momento de construir cada pronóstico requiere comprobación independiente.

9.2. Análisis de resultados

Los resultados permiten responder de manera matizada a la hipótesis planteada. Durante la validación, M4 redujo el LogLoss respecto del modelo base, con 0.978612 frente a 0.989547 de M0, pero M0 conservó el menor MAE medio, con 0.918332 frente a 0.921895 de M4. Por tanto, la información adicional mejoró la calidad de las probabilidades 1X2 en esa partición, aunque no mejoró simultáneamente la precisión media de las intensidades de gol.

En el conjunto de prueba final tampoco existe una mejora uniforme. M3 obtiene el menor MAE

medio, con 0.894173 frente a 0.902306 de M0, pero M0 registra el menor LogLoss entre los modelos, con 1.033076 frente a 1.033868 de M3. M4 presenta un MAE medio de 0.899439 y un LogLoss de 1.036739. En consecuencia, las variables adicionales pueden aportar información útil para determinados componentes del pronóstico sin garantizar una mejora simultánea en todas las métricas fuera de muestra.

En consecuencia, la evidencia obtenida respalda sólo parcialmente la hipótesis inicial. El principal aprendizaje es que incorporar variables adicionales de desempeño reciente puede mejorar ciertos aspectos de la predicción sin garantizar una mejora general de las probabilidades finales de victoria, empate o derrota. La utilidad de una especificación más compleja depende, por tanto, de la dimensión del desempeño predictivo que se evalúe.

10. Ejemplo de pronóstico individual

Una vez entrenados los modelos, la función `predecir_partido` permite generar un pronóstico para un encuentro específico. La función recibe el equipo local, el equipo visitante, una fecha de corte y la especificación que se desea utilizar. Para construir las variables del partido se consideran únicamente encuentros anteriores a la fecha indicada.

Como ejemplo se analiza un enfrentamiento entre Arsenal y Manchester City con fecha de corte 20 de septiembre de 2026, utilizando la especificación `M0_Base`.

Cuadro 8: Predicción ilustrativa para Arsenal vs. Manchester City.

Magnitud	Valor
Modelo utilizado	M0 Base
Intensidad de goles locales, $\hat{\lambda}_L$	1.537597
Intensidad de goles visitantes, $\hat{\lambda}_V$	1.265612
Probabilidad de victoria local	43.6462 %
Probabilidad de empate	25.0000 %
Probabilidad de victoria visitante	31.3538 %
Marcador modal	1–1
Probabilidad del marcador 1–1	11.7957 %

Las probabilidades de los tres resultados suman aproximadamente 100 %, salvo pequeñas diferencias por redondeo. El marcador modal 1–1 no contradice que la victoria local tenga la mayor probabilidad agregada, ya que esta última reúne todos los marcadores en los que Arsenal anota más goles que Manchester City.

El marcador exacto se obtiene construyendo una matriz de probabilidades con valores de cero a diez goles para cada equipo. En cambio, las probabilidades de victoria local, empate y victoria visitante se calculan directamente mediante la distribución de Skellam.

11. Reproducibilidad, supuestos y limitaciones

11.1. Reproducibilidad y control de calidad

El flujo de análisis se organiza de manera secuencial desde la carga del histórico hasta la evaluación y la predicción individual. La matriz `premier_training_data.csv` funciona como una caché de las variables prepartido ya construidas, lo que permite repetir la estimación sin recalculer todo el histórico en cada ejecución.

Si cambia la base histórica, el módulo `wc_predictor.py` o alguno de los hiperparámetros utilizados para construir las características, la matriz debe regenerarse antes de volver a estimar los modelos.

Antes del entrenamiento se verifica que los predictores y las variables objetivo sean numéricos y finitos. También se comprueba que no existan partidos duplicados según fecha, equipo local y equipo visitante. Estas validaciones buscan asegurar que las cinco especificaciones se estimen sobre una base consistente.

11.2. Supuestos del modelo

El sistema supone independencia condicional entre los goles del equipo local y los del visitante una vez consideradas las variables explicativas. Bajo este supuesto, ambas cantidades se modelan mediante distribuciones de Poisson independientes y sus probabilidades 1X2 se obtienen mediante la distribución de Skellam.

El MAE y el Log-Loss evalúan aspectos diferentes del desempeño. El MAE mide la precisión de las intensidades de gol, mientras que el Log-Loss evalúa la calidad de las probabilidades asignadas a victoria local, empate y victoria visitante. Por esta razón, una especificación puede mejorar una métrica sin mejorar necesariamente la otra.

11.3. Alcance y limitaciones

Los resultados corresponden exclusivamente a la Premier League y al periodo disponible en el histórico utilizado; no deben extrapolarse automáticamente a otras ligas o temporadas futuras. Las cuotas de apertura se utilizan únicamente como referencia probabilística y no como variables explicativas de los modelos. El análisis no evalúa rentabilidad económica, estrategias de apuesta, comisiones ni restricciones de ejecución.

Como extensiones posteriores pueden estudiarse otros esquemas de validación temporal, calibración de hiperparámetros y modelos capaces de representar dependencias adicionales entre los goles de ambos equipos.

12. Conclusiones

El proyecto permitió desarrollar y evaluar un predictor probabilístico de resultados de la Premier League a partir de información histórica de los equipos. Mediante variables de fortaleza Elo, promedios de goles y forma reciente, se estimaron intensidades de gol con regresiones de Poisson y se obtuvieron probabilidades de victoria local, empate y victoria visitante. La separación cronológica entre entrenamiento, validación y prueba permitió evaluar las distintas especificaciones sobre partidos posteriores a los utilizados para su estimación.

En relación con la pregunta de investigación, los resultados muestran que incorporar información adicional sobre fortaleza y desempeño reciente puede aportar capacidad predictiva, aunque la mejora depende de la métrica y del periodo evaluado. En validación, M0 obtuvo el menor MAE medio, con 0.918332, mientras que M4 alcanzó el menor LogLoss entre los modelos, con 0.978612 frente a 0.989547 de M0. En la prueba final, M3 presentó el menor MAE medio, con 0.894173, mientras que M0 obtuvo el menor LogLoss, con 1.033076, seguido por M3 con 1.033868. Por tanto, la evidencia respalda parcialmente la hipótesis planteada: las variables adicionales pueden mejorar determinados aspectos del pronóstico, pero no producen una mejora uniforme en la estimación de goles y en las probabilidades 1X2.

La comparación con las probabilidades implícitas en las cuotas de apertura proporcionó una referencia externa para dimensionar el desempeño de los modelos. El mercado obtuvo un LogLoss de 0.9705 en validación y de 1.02 en prueba, inferior al de las especificaciones desarrolladas en ambos periodos. Este resultado muestra la dificultad de superar probabilidades que sintetizan información adicional disponible antes de los encuentros y no implica, por sí mismo, conclusiones sobre rentabilidad económica.

En conjunto, el principal aprendizaje del análisis es que aumentar la complejidad del modelo mediante nuevas variables no garantiza una mejora uniforme fuera de muestra. La evaluación debe considerar conjuntamente la precisión de las intensidades de gol, la calidad de las probabilidades 1X2 y su estabilidad temporal. Los supuestos propios del modelo Poisson, la independencia condicional entre los goles y la necesidad de mantener consistencia entre el histórico y las variables prepartido delimitan el alcance de los resultados y constituyen puntos relevantes para futuras extensiones.

A. Diccionario de variables

A.1. Variables de la base histórica consolidada

La base `E0_consolidado.csv` contiene 34 variables de identificación, resultados, estadísticas del encuentro, cuotas de mercado y goles esperados.

Cuadro 9: Variables de `E0_consolidado.csv`.

Variable	Significado
<i>Identificación y resultados</i>	
Div	Código de la división o competición; en la Premier League corresponde a E0.
Date	Fecha del partido.
HomeTeam	Equipo local.
AwayTeam	Equipo visitante.
FTHG	Goles finales del equipo local.
FTAG	Goles finales del equipo visitante.
FTR	Resultado final: H, D o A.
HTHG	Goles del local al medio tiempo.
HTAG	Goles del visitante al medio tiempo.
HTR	Resultado al medio tiempo: H, D o A.
<i>Tiros y tiros a puerta</i>	
HS	Tiros realizados por el equipo local.
AS	Tiros realizados por el equipo visitante.
HST	Tiros a puerta del equipo local.
AST	Tiros a puerta del equipo visitante.
<i>Otras estadísticas del encuentro</i>	
HC	Saques de esquina del equipo local.
AC	Saques de esquina del equipo visitante.
HF	Faltas cometidas por el equipo local.
AF	Faltas cometidas por el equipo visitante.
HY	Tarjetas amarillas del equipo local.
AY	Tarjetas amarillas del equipo visitante.
HR	Tarjetas rojas del equipo local.
AR	Tarjetas rojas del equipo visitante.
Referee	Árbitro del encuentro.
<i>Cuotas del mercado</i>	
B365H	Cuota Bet365 para victoria local.
B365D	Cuota Bet365 para empate.
B365A	Cuota Bet365 para victoria visitante.

Variable	Significado
AvgH	Cuota promedio de apertura para victoria local.
AvgD	Cuota promedio de apertura para empate.
AvgA	Cuota promedio de apertura para victoria visitante.
AvgCH	Cuota promedio de cierre para victoria local.
AvgCD	Cuota promedio de cierre para empate.
AvgCA	Cuota promedio de cierre para victoria visitante.
<i>Goles esperados</i>	
HxG	Goles esperados del equipo local.
AxG	Goles esperados del equipo visitante.

A.2. Variables del conjunto de modelación

La matriz `premier_training_data.csv` contiene 24 variables: identificadores, variables preparado y los goles observados utilizados como variables objetivo.

Cuadro 10: Variables de `premier_training_data.csv`.

Variable	Significado
<i>Identificación y Elo</i>	
Date	Fecha del encuentro.
HomeTeam	Equipo local.
AwayTeam	Equipo visitante.
elo_home	Elo del equipo local antes del partido.
elo_away	Elo del equipo visitante antes del partido.
elo_diff	Diferencia entre Elo local y visitante.
<i>Promedios de goles</i>	
gf_home	Promedio estacional de goles a favor del equipo local.
ga_home	Promedio estacional de goles en contra del equipo local.
gf_away	Promedio estacional de goles a favor del equipo visitante.
ga_away	Promedio estacional de goles en contra del equipo visitante.
<i>Forma reciente</i>	
form_gf_home	Goles recientes a favor del equipo local.
form_ga_home	Goles recientes en contra del equipo local.
form_gf_away	Goles recientes a favor del equipo visitante.
form_ga_away	Goles recientes en contra del equipo visitante.
<i>Tiros recientes</i>	
shots_for_home	Tiros recientes realizados por el local.
shots_against_home	Tiros recientes concedidos por el local.

Variable	Significado
shots_for_away	Tiros recientes realizados por el visitante.
shots_against_away	Tiros recientes concedidos por el visitante.
<i>Tiros a puerta recientes</i>	
sot_for_home	Tiros a puerta recientes del local.
sot_against_home	Tiros a puerta recientes concedidos por el local.
sot_for_away	Tiros a puerta recientes del visitante.
sot_against_away	Tiros a puerta recientes concedidos por el visitante.
<i>Variables objetivo</i>	
home_goals	Goles observados del equipo local.
away_goals	Goles observados del equipo visitante.

Referencias

- [1] Hvattum, L. M., & Arntzen, H. (2010). Using ELO ratings for match result prediction in association football. *International Journal of Forecasting*, 26(3), 460–470. Disponible en: <https://www.sciencedirect.com/science/article/pii/S0169207009001708>.
- [2] Loukas, K., Karapiperis, D., Feretzakis, G., & Verykios, V. S. (2024). Predicting Football Match Results Using a Poisson Regression Model. *Applied Sciences*, 14(16), 7230. doi:10.3390/app14167230. Disponible en: <https://www.mdpi.com/2076-3417/14/16/7230>.
- [3] Foulley, J.-L. (2021). More on verification of probability forecasts for football outcomes: Score decompositions, reliability, and discrimination analyses. *arXiv preprint arXiv:2106.14345*. Disponible en: <https://arxiv.org/pdf/2106.14345>.
- [4] Football-Data (2026). *Football Results, Statistics and Soccer Betting Odds Data*. Disponible en: <https://www.football-data.co.uk/data.php>. Consultado en septiembre de 2026.